Øving 5

Deloppgave 1:

Kjøring

Programmet kjører automatisk og leser filen som er oppgitt i oppgaven fra nettet. Om man heller vil kjøre en egen fil kan man kompilere programmet og sette filen som args[0].

Løsning

Kollisjoner blir håndtert ved bruk av en lenket liste gjennom bruk av klassen «Node». Når en Node hasher til samme verdi som en allerede eksisterende Node, blir den eksisterende noden satt som «next» for den nye noden, mens den nye noden blir plassert i listen.

Utskrift oppgave 1:

Figur 1: Kollisjoner som oppstår ved kjøring av vedlagt fil.

```
PART 1
Finds Tobias Skipevåg Oftedal: true
Finds Ola Nordmann: false
TableSize: 167
Total collisions: 42
Collisions per person: 0.3111111111111111
Load: 135
Load-factor: 0.8083832335329342
```

Figur 2: Oversikt over kollisjoner og load for kjøringen

Deloppgave 2:

Oppgave 1

Valg av tabellstørrelse «m» er påvirket av hashe-funksjonen som brukes i denne oppgaven. Oppgaven er løst ved bruk av hashfunksjon basert på restdivisjon, noe som gjør at «m» blir ideelt et primtall. Som beskrevet i oppgaven må «m» også være over 10-millioner. Koden under lar m være 1008676.

Oppgave 2

```java
public static Integer[] createRandomIntegerArray(int length) {
  Integer[] randomArray = new Integer[length];

  int a = 1;
  Random random = new Random();
  for (int i = 0; i < length; i++) {
    a += random.nextInt(200);
    randomArray[i] = a;
  }
  Collections.shuffle(Arrays.asList(randomArray));
  return randomArray;
}
```

Figur 3: Oversikt over metode som lager en tabell med m unike tilfeldige tall.

Oppgave 3

Underliggende bilder beskriver en implementasjon av linærprobing og en dobbelhashing. Variablen «collision» beskriver hvor mange kollisjoner som kan oppstå når man hopper. Load variablen beskriver hvor mange tall som har blitt lagt til i hashtabellen.

```java
@Override
public void put(Integer integer) {
  if (tableSize <= load){
    throw new RuntimeException("Full");
  }

  //hash
  int pos = hash(integer);

  while (table[pos] != null) {

    pos = (pos + 1) % tableSize;
    collisions++;

  }
  table[pos] = integer;
```

Figur 4: Oversikt av hopp ved bruk av linær probing.

```java
public void put(Integer integer) {
  if (load >= tableSize){
    throw new RuntimeException("Full");
  }
  for (int i = 0; i < tableSize; ++i) {
    int j = probe(hash(integer), hash2(integer), i, tableSize);
    if (table[j] == null) {
      table[j] = integer;
      load++;
      return;
    }
    collisions++;
  }
}
```

Figur 5: Oversikt av hopp ved bruk av dobbelhashing.

Oppgave 4

```
PART 2
Size of table: 10000019 (Prime 10000019 ~ 10 million)
Amount of collisions:
```

Percentage	Linear Probing	Double Hashing
50.0%	2393610	1965666
80.0%	13700022	8869258
90.0%	28850364	16417696
99.0%	223242727	87463049
100.0%	200622451122	74068074713

```
Size of table: 10000019 (Prime 10000019 ~ 10 million)
Amount of time in ms:
```

Percentage	Linear Probing	Double Hashing
50.0%	304	370
80.0%	849	908
90.0%	1053	1080
99.0%	1740	1309
100.0%	459526	99463

Vi ser at bruk av lineære prober generelt sett gir et høyere forbruk av tid, samt et større antall kollisjoner. I eksempelet har til og med den lineære proben gitt et resultat som overstiger Integer.Max_VALUE for 100% fyllingsgrad, noe som førte til at denne verdien måtte byttest til en long. Det interessante her er hvor mye stigningen er fra bare 99% til 100%. Skulle man prøve å lage en graf av dette kunne det se slik ut:

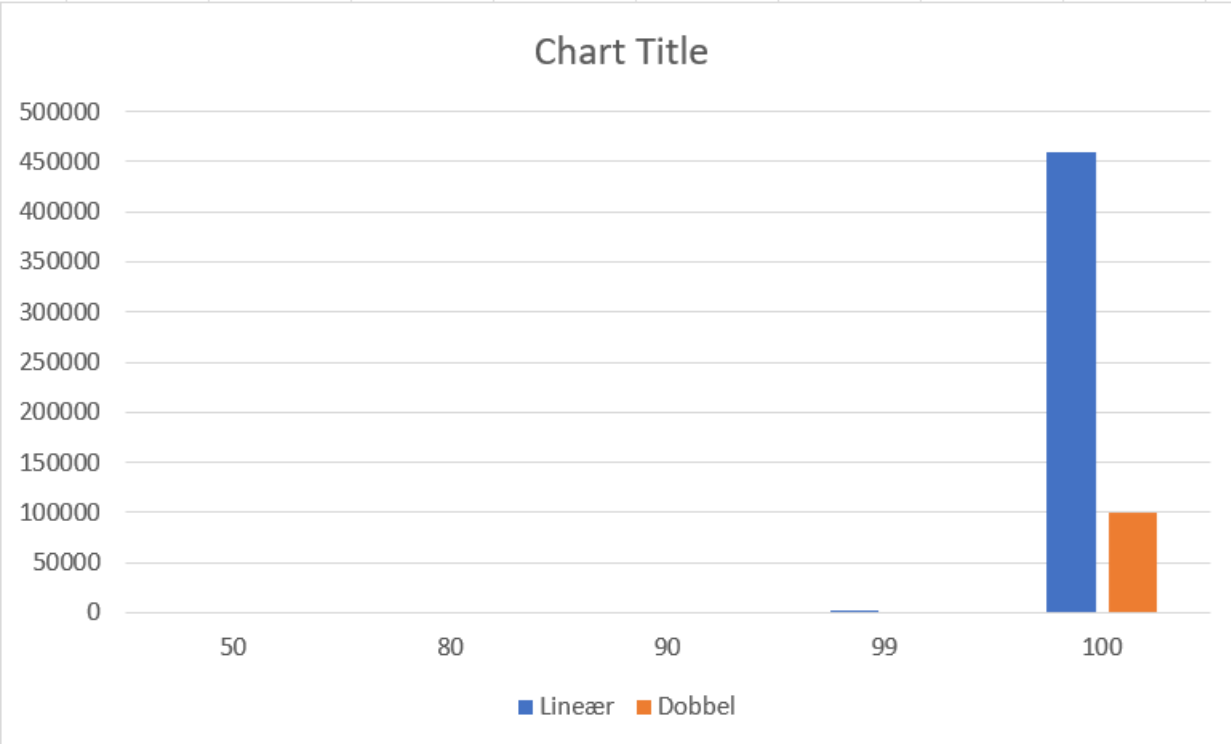

Grafen viser hvor mye tidsforbruket øker for den lineære proben sammenlignet med dobbel hashing. For lavere fyllingsgrad ser man at økningen i tidsbruk ikke er like stor:

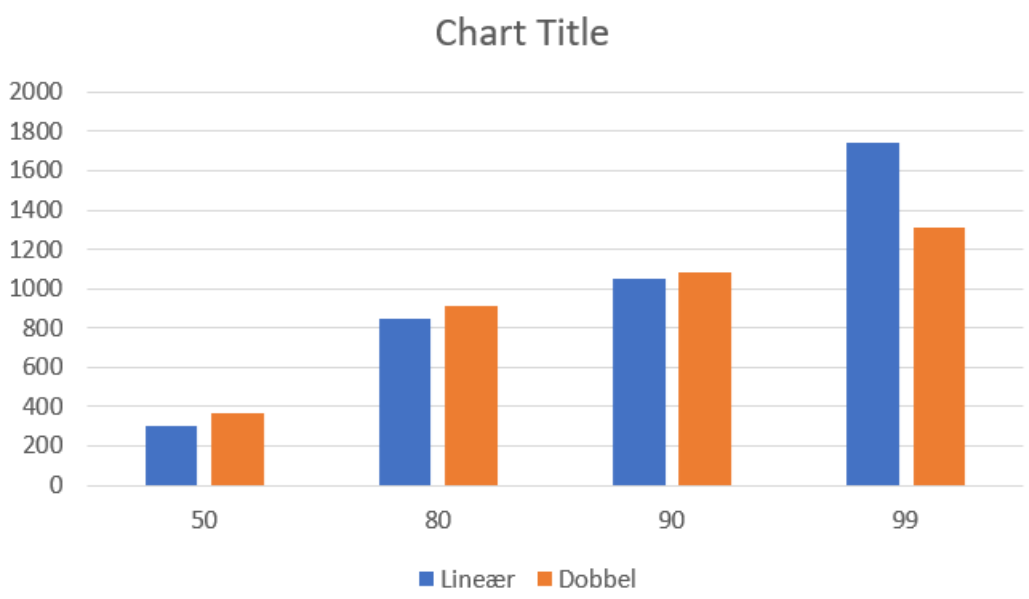

Generelt har dobbel probing lavere tidsbruk når man går mot 100% fyllingsgrad, men forskjellen er ikke i nærheten så stor som for 100%. Dette baseres på at når man f.eks skal sette inn det siste elementet vha lineær probing, vil man i gjennomsnitt bruke (tabellstørrelse / 2) prober før man finner rett posisjon, noe som er veldig mye.

Oppgave 6

a) Sammenligner man kollisjoner og tid brukt ser man at det er en viss korrelasjon mellom tidsbruk og kollisjoner. Noe som gir mening, ettersom enhver kollisjon vil føre til en ekstra probe, som tar tid. Sammenhengen er ikke lineær, noe man lett ser om man ser på de første verdiene, som har veldig stor forskjell i antall kollisjoner selv om tidtakingen er ganske lik, men dette kan i en viss grad skyldes andre faktorer.

b) Det er grenser for hvor full en hashtabell bør være for å sikre optimal ytelse og raske operasjoner. Denne grensen avhenger av tabellens lastfaktor, som er forholdet mellom antall elementer i tabellen og tilgjengelige plasser i den. Ideelt sett ønsker vi å holde lastfaktoren lav nok til å unngå mange kollisjoner, samtidig som man utnytter tabellens

plass. Hvis lastfaktoren blir for høy, fører det til flere kollisjoner, noe som negativt påvirker kjøretiden. Generelt er en lastfaktor på rundt 0,7 eller lavere det mest optimale.

c) Ytelsen til ulike typer hashing, som lineær og dobbel hashing, kan variere avhengig av faktorer som størrelsen på hashtabellen og lastfaktoren. Lineær probing gir best ytelse ved lav fyllingsgrad, men ved høy fyllingsgrad kan det oppstå en betydelig økning i antall kollisjoner, noe som fører til redusert ytelse. Dobbel hashing anvender en annen hashfunksjon enn lineær probing, og får dermed en mer jevnere fordeling av elementer. Dette fører til bedre ytelse enn lineær probing ved høyere fyllingsgrad.

Gjennomsnittelig tidsbruk for innsetning av et nytt tall i en hash-tabell er begrenset av $\frac{1}{1-a}$ der a betegner lastfaktoren. I og med at hashfunksjonene er O(1), avhenger de fremdles på mengden kollisjoner som oppstår. Forskjell på tid ved kjøring er grunnet mindre probesekvenser i dobbel hashfunksjonen.